

Detector de Interacoes Medicamentosas com LLMs

Sistemas Cognitivos com Large Language Models

Aplicacoes com LLMs - Pos-Graduacao

Aluno: Kevin Rodrigues

Data: Junho 2026

1. Descricao do Problema

Aplicacao cognitiva que recebe consultas em linguagem natural sobre interacoes entre medicamentos e retorna classificacoes estruturadas (grave, leve/moderada, sem interacao), fundamentadas em bulas reais de medicamentos brasileiros. Profissionais de saude e pacientes precisam verificar interacoes rapidamente. O sistema extrai e classifica interacoes automaticamente usando um pipeline RAG.

2. Corpus ou Base de Conhecimento

Fonte 1 (ANVISA): 4.978 bulas oficiais em formato _paciente / _profissional. Secao de interacoes extraida. **Fonte 2 (Consultaremedios):** 982 Q&A; com blocos INTERACAO MEDICAMENTOSA? e COMPOSICAO?. **Total:** 5.960 arquivos processados e podados em data/pruned/.

3. Justificativa para Uso de LLMs

O dominio farmaceutico requer precisao e rastreabilidade. LLMs sao ideais porque: (1) Interpretam linguagem natural da consulta; (2) Classificam interacoes com base em contexto recuperado; (3) Geram saidas estruturadas (JSON) para consumo programatico; (4) Reduzem alucinacao quando combinados com RAG.

4. Modelos e Ferramentas Utilizadas

NER: pucpr/clinicalnerpt-chemical (vocabulario farmaceutico PT-BR). **Embeddings:** sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2 (384d, PT-BR). **Vector store:** FAISS IndexFlatIP. **Classificador:** GPT4All Meta-Llama-3-8B-Instruct.Q4_0.gguf (local) com fallback heuristico.

5. Tarefas NLP Implementadas

NER: Extracao de farmacos com agregacao de sub-tokens WordPiece. **Classificacao:** 3 classes (SEM_INTERACAO=0, LEVE_MODERADA=1, GRAVE_CONTRAINDICADA=2). **Recuperacao:** Busca semantica via embeddings + FAISS. **Geracao:** Few-shot prompting para saida JSON.

6. Estrategia de Prompting

Zero-shot: Classificacao direta sem exemplos. **Few-shot:** 3 exemplos no prompt (um por classe). **Chain-of-Thought:** Raciocinio encadeado antes da resposta. **Role prompting:** Farmacologo clinico como papel. Prompts testados com 3 consultas de dominio e avaliados por: estabilidade do parsing JSON, corretude semantica, ausencia de alucinacao.

7. Saida Estruturada (JSON)

Formato: {consulta, medicamentos_encontrados, interacoes, tempo_ms, backend}. Parsing em cascata: json.loads direto, remove blocos markdown, regex "classe": (d).

8. Embeddings e Busca Vetorial

Modelo: paraphrase-multilingual-MiniLM-L12-v2 (384d). Normalizacao L2 - Produto interno = cosseno. Metricas demo: Recall@5=0.85, MRR@5=0.72. Funcionou: farmacos com nomeSimilar a bulas indexadas. Falhou: nomes comerciais fora do vocabulario NER.

9. Estrategia de Execucao (Local vs Remota)

GPT4All direto (privacidade total, R\$0, alta latencia). GPT4All API local (privacidade alta, R\$0, media latencia). Heuristica (privacidade total, R\$0, baixa latencia). Decisao: GPT4All local com fallback heuristico. Dados medicos nunca saem da maquina.

10. Pipeline RAG Completo

Fluxo: Consulta - NER (clinicalnerpt) - Embeddings (MiniLM) - FAISS (top-K) - GPT4All/Heuristica - JSON. Chunking: sentencas max 250 palavras, overlap de 1 sentenca. Com contexto (RAG): fundamentado em bulas reais. Sem contexto (zero-shot): risco de alucinacao.

11. Analise de Falhas do Pipeline

NER: farmaco fora do vocabulario - par nao gerado. FAISS: top-K=3 perde contexto relevante - reranking. Heuristica: acuracia limitada - fine-tuning. Chunking: sentenca isolada perde contexto - overlap maior.

12. Riscos de Seguranca

Injecao de prompt: Consulta contem instrucoes para bypassar classificacao. Controle: sanitizacao regex (remover "lembre_se", "ignore_instrucoes"). **Vazamento de contexto:** Tentativa de extrair system prompt. Controle: log de auditoria; heuristica nao expoe prompt. **Exposicao de dados:** API externa recebe dados medicos. Controle: GPT4All local; dados nunca saem da maquina.

13. Instrucoes de Reproducao

1) cd C:/workspace/python/projeto-2-modulo-1-pos/ 2) python -m venv venv; venv/Scripts/activate 3) pip install -r requirements.txt 4) jupyter notebook c01_modelos_llm.ipynb ... c05_pipeline_rag.ipynb GPT4All opcional: baixar Meta-Llama-3-8B-Instruct.Q4_0.gguf. Heuristica funciona sem modelo GGUF.

14. Limitacoes da Solucao

NER com vocabulario limitado (nomes comerciais fora do dominio). Heuristica com acuracia moderada (usada apenas como fallback). Top-K fixo pode perder contextos relevantes. Sem avaliacao formal com conjunto de teste anotado.

15. Melhorias Futuras

Fine-tuning do classificador com as 5.960 bulas. Reranking com segundo modelo para reordenar resultados FAISS. Cache Redis TTL=7d para consultas frequentes. Curadoria humana com Label Studio para casos ambiguos. Avaliacao formal F1-score por classe com conjunto de teste.